

Ciência de Dados
Inteligência Artificial
Anhembi Morumbi

Leandro Siqueira Soares

Projeto (Comparativo de Modelos Preditivos)

São Paulo
2026

Ciência de Dados
Inteligência Artificial
Anhembi Morumbi

Projeto (Comparativo de Modelos Preditivos)

São Paulo
2026

1. Introdução e Objetivo

Este relatório apresenta o desenvolvimento, otimização e avaliação de um sistema de classificação utilizando três abordagens distintas de Aprendizado de Máquina: Regressão Logística, Random Forest e o recém-integrado K-Nearest Neighbors (KNN). O objetivo é avaliar a capacidade de cada algoritmo em discriminar corretamente as classes do problema, focando na maximização das métricas de desempenho após a calibração de hiperparâmetros.

2. Metodologia e Pipeline de Dados

Para garantir a robustez estatística e evitar o vazamento de dados (*data leakage*), o projeto foi estruturado utilizando a classe Pipeline do *Scikit-Learn*. O fluxo seguiu as seguintes etapas:

1. Padronização dos Dados (StandardScaler): Aplicada de forma idêntica para todos os modelos dentro do pipeline. Esta etapa foi indispensável para o sucesso do KNN, visto que o algoritmo baseia-se em distâncias euclidianas e seria severamente distorcido caso as variáveis apresentassem escalas diferentes.

2. Otimização via Optuna: A biblioteca *Optuna* realizou uma busca Bayesiana inteligente de hiperparâmetros ao longo de 30 iterações por modelo, focando em extrair o potencial máximo de cada arquitetura.

3. Ajuste Fino de Threshold: O limiar de decisão foi otimizado através da curva *Precision-Recall*, visando o perfeito equilíbrio entre falsos positivos e falsos negativos.

3. Análise dos Resultados e Gráficos

3.1. Desempenho Global (Curva ROC e AUC)

A análise da Curva ROC revela que todos os três modelos atingiram um desempenho de excelência na capacidade de separação das classes:

- **Regressão Logística: AUC = 0.90**
- **KNeighborsClassifier: AUC = 0.90**
- **Random Forest: AUC = 0.88**

A Regressão Logística e o KNN empataram como os melhores modelos em termos de área sob a curva (AUC), demonstrando uma probabilidade de 90% de classificar corretamente uma instância positiva escolhida aleatoriamente em relação a uma negativa. O Random Forest apresentou uma performance ligeiramente menor, mas ainda altamente competitiva (88%).

3.2. Análise Detalhada (Matrizes de Confusão)

A avaliação minuciosa das previsões revela um comportamento extremamente consistente entre os algoritmos:

Modelo	Verdadeiros Negativos (0)	Falsos Positivos (1Errado)	Falsos Negativos (0 Errado)	Verdadeiro Positivos (1)
Regressão Logística	57	8	7	114
Random Forest	57	8	7	114
KNN (Adicionado)	56	9	7	114

- **Equilíbrio no Alvo (Classe 1):** Absolutamente todos os três modelos acertaram exatamente o mesmo número de instâncias da classe positiva (114 acertos contra apenas 7 erros de falsos negativos). Isso

prova que a otimização de threshold focada em capturar a classe 1 funcionou perfeitamente em todas as frentes.

- **Comportamento do KNN:** O KNN integrado mostrou-se perfeitamente alinhado com os modelos consagrados. Ele cometeu apenas um erro a mais de falso positivo (9 contra 8 dos outros modelos) na classe zero, o que indica que a estrutura espacial dos dados possui fronteiras de decisão muito bem definidas, permitindo que a vizinhança local (KNN) capture o padrão tão bem quanto abordagens lineares ou árvores.

4. Conclusão

A inclusão do KNN provou-se altamente valiosa, alcançando o topo do desempenho do projeto lado a lado com a Regressão Logística (AUC = 0.90).

Dado o empate técnico nas matrizes de confusão e métricas, a escolha do modelo final pode levar em consideração critérios operacionais: a Regressão Logística e o KNN destacam-se como as escolhas ideais pela simplicidade e poder de generalização neste conjunto de dados. O projeto alcançou o sucesso pretendido, evidenciando o impacto positivo do tratamento de escala e da otimização automatizada de hiperparâmetros na engenharia de Machine Learning.